



Kierunek studiów: Geoinformacja

Nr albumu: 444861

Błażej Kościański

**Porównanie metod określania zmian struktury
przestrzennej w kontekście analiz zmian
kategorii pokrycia terenu**

*Comparison of methods for determining changes in
spatial patterns in the context of land cover change
analyses*

Praca magisterska napisana
w Instytucie Geoekologii i Geoinformacji
pod kierunkiem
dr. hab. Jakuba Nowosada

Poznań, 2023

Streszczenie

Abstrakt

Słowa kluczowe: zmiany pokrycia terenu, struktura przestrzenna, miary odległości, miary niepodobieństwa, ekologia krajobrazu

Abstract

The abstract must be consistent with the above text.

Keywords: land cover changes, spatial pattern, distance measures, dissimilarity measures, landscape ecology

Spis treści

Streszczenie	3
1 Wprowadzenie	5
2 Metody	9
2.1 Struktury przestrzenne	10
2.2 Metryki krajobrazowe	10
2.3 Sygnatury przestrzenne	11
2.4 Metody analiz różnic pokrycia terenu	13
2.5 Miary odległości i niepodobieństwa	14
2.6 Obliczenie niepodobieństwa rastrów	15
3 Materiały	17
3.1 Symulowanie rastrów o określonej kompozycji i konfiguracji przestrzennej .	17
3.2 Przygotowanie ankiety	21
3.3 Dane CORINE Land Cover	21
4 Wyniki	23
5 Podsumowanie	33

Rozdział 1

Wprowadzenie

Informacje geograficzne są wynikiem selekcji i przetwarzania danych związanych z otaczającą nas przestrzenią geograficzną. Pozwalają na bardziej zrozumiałe i efektywne analizowanie, modelowanie oraz interpretowanie złożonych zjawisk i procesów zachodzących w naszym otoczeniu. Informacje geograficzne i ich aspekty nie stanowią niepodważalnych faktów, lecz często powstają w wyniku działań jednostek, jak i wspólnych wysiłków grup ekspertów, którzy zajmują się wyborem, analizą i klasyfikacją danych geograficznych (Comber et al., 2005). W procesie tworzenia informacji geograficznych istnieje zatem pewien stopień subiektywności, który może wpłynąć na ostateczną postać tych informacji, ich interpretację, jak i na ich użyteczność w kontekście innych zastosowań. Przykładem informacji geograficznej, której ostateczna postać zależna jest od założeń przyjętych w trakcie tworzenia danych przestrzennych, jest pokrycie terenu.

Przyjmuje się, że termin pokrycie terenu obejmuje zbiór wszelkich elementów obecnych na powierzchni Ziemi (**dodać ref**). W elementy pokrycia terenu włączają się obiekty związane z działalnością człowieka, skutkami sił przyrody oraz wszelkie inne istniejące obiekty, które mogą znaleźć się w przestrzeni geograficznej (**dodać ref**). Tworzenie dokładnych i wiarygodnych danych dotyczących pokrycia terenu jest niezbędne w kontekście wielu zastosowań, takich jak planowanie przestrzenne (**dodać ref**), ochrona środowiska (**dodać ref**), czy analiza zmian klimatycznych (**dodać ref**). Ostateczna forma tych danych jest jednak w dużej mierze determinowana przez wybory i założenia

dokonywane w procesie ich tworzenia. W tym kontekście, analiza pokrycia terenu staje się istotnym polem badań, które skupia się na zarówno na technicznych aspektach zbierania danych, jak i na ich semantycznej interpretacji (**dodać ref**).

Dane oraz wynikowe mapy pokrycia terenu są rezultatem złożonego procesu przetwarzania i analizy danych przestrzennych najczęściej w postaci obrazów satelitarnych (Jasiewicz et al., 2015). Na początku tego procesu, satelity wyposażone w sensory rejestrują obrazy Ziemi z różnych zakresów widmowych. Dane pochodzące z teledetekcji często mają postać danych rastrowych, gdzie informacje przestrzenne są zapisane w formie regularnej siatki komórek lub punktów (Głazewski, 2006). W modelu danych rastrowych każda z tych komórek lub punktów przechowuje jedną wartość, która stanowi reprezentację jakiejś charakterystyki danego fragmentu powierzchni Ziemi. Obrazy uzyskane w procesie teledetekcji mogą być interpretowane manualnie przez grupy specjalistów. Pozwala to na uzyskanie map pokrycia terenu o wysokiej dokładności, kosztem długiego procesu ich tworzenia (**dodać ref**). Dużo mniej czasochłonną metodą jest przetwarzanie przy użyciu algorytmów. Umożliwiają one względnie szybką, półautomatyczną identyfikację i klasyfikację różnych typów powierzchni kosztem mniejszej dokładności mapy wynikowej (**dodać ref**). Ostatecznie, dane przekształcone w mapy pokrycia terenu mogą posłużyć do analiz zmian pokrycia terenu (**dodać ref**).

Celem analiz zmian pokrycia terenu jest przede wszystkim monitorowanie i pogłębienie aktualnej wiedzy na temat ewolucji otaczającego nas krajobrazu (**dodać ref**). Jest to istotne w kontekście ochrony przyrody (**dodać ref**), planowania przestrzennego (**dodać ref**), oceny wpływu inwestycji (**dodać ref**) i infrastruktury na środowisko (**dodać ref**), a także w badaniach naukowych dotyczących zmian klimatycznych (**dodać ref**), bioróżnorodności (**dodać ref**) oraz innych procesów ekologicznych (Lu et al., 2004). Dzięki analizie zmian pokrycia terenu można identyfikować obszary zagrożone degradacją, monitorować skutki urbanizacji, deforestacji czy erozji, co umożliwia podejmowanie odpowiednich działań w celu zrównoważonego zarządzania środowiskiem i zachowaniem jego integralności.

W badaniach nad zmianami pokrycia terenu wykorzystuje się różnorodne metody analityczne. Niemniej jednak, wiele z tych technik koncentruje się na analizie zmian na

poziomie indywidualnych komórek w siatce rastra (Lu et al., 2004). Choć podejście to może dostarczać użytecznych informacji dotyczących trendów zmian pokrycia terenu na niewielkich obszarach, charakteryzuje się ono istotnymi ograniczeniami w kontekście interpretacji wyników. Szczególnie w przypadku badań obejmujących rozległe terytoria, takie jak kraje czy nawet kontynenty, bardziej efektywne staje się zastosowanie metod opartych na analizie struktur przestrzennych (Netzel et al., 2015). Głównym założeniem tych metod jest przekształcenie danych z postaci pojedynczych wartości komórek rastra w sygnatury przestrzenne, a następnie porównanie ich ze sobą za pomocą miar odległości i niepodobieństwa.

Sygnatury przestrzenne stanowią statystyczny opis struktur przestrzennych kategorii pokrycia terenu na mniejszych, wydzielonych obszarach w obrębie całego zbioru danych. W celu porównania ze sobą dwóch sygnatur przestrzennych, wykorzystywane są miary niepodobieństwa. Umożliwiają one określenie w jakim stopniu dwa analizowane obszary się od siebie różnią pod względem kompozycji oraz konfiguracji przestrzennej. Opracowane zostało wiele różnych miar niepodobieństwa, takich jak odległość euklidesowa, odległość Canberra, metryka Wave Hedges, współczynnik podobieństwa Jaccarda, odległość Jensena-Shannona czy dywergencja Pearsona (Cha, 2007). Współcześnie jednak nie określono, która z tych miar jest najbardziej zgodna zarówno z postrzeganiem przez człowieka, jak i wpływem zmian na procesy środowiskowe.

Celem tej pracy było porównanie metod określania zmian struktury przestrzennej kategorii pokrycia terenu w kontekście ich korelacji z postrzeganiem zmian przestrzennych przez ludzi. Zbiór rastrów symulowany aby uzyskać pełną reprezentację wszystkich możliwych wartości kompozycji, jak i konfiguracji przestrzennej. Na podstawie tych danych przeprowadzona została ankieta, w której zadaniem respondentów było określenie stopnia podobieństwa między parami rastrów. Badanie przeprowadzone zostało na rastrach składających się wyłącznie z dwóch lub trzech kategorii. Wyniki ankiety zestawione zostały z wartościami 45 miar niepodobieństwa. Na tej podstawie, do dalszej analizy wybrane zostały 4 miary niepodobieństwa charakteryzujące się największą zgodnością z ludzką percepcją zmian przestrzennych. W kolejnym etapie na podstawie zbioru danych o pokryciu terenu Corine Land Cover (CLC) stworzone zostały mapy niepodobieństwa

pokrycia terenu dla obszaru Polski dla lat 1990 i 2018. Mapy te stworzone zostały w oparciu o metody wywodzące się z ekologii krajobrazu z wykorzystaniem miar niepodobieństwa wybranych na podstawie wyników ankiety. Następnie mapy te zostały ze sobą porównane i opisane, na podstawie czego scharakteryzowane zostały kluczowe różnice wynikające z zastosowania każdej z wykorzystanych miar.

Rozdział 2

Metody

W tym rozdziale opisane są kolejno wszystkie zagadnienia kluczowe do zrozumienia tematyki określania zróżnicowania struktur przestrzennych w kontekście zmian pokrycia terenu. Pierwszym omawianym zagadnieniem są struktury przestrzenne, a także koncepcje kompozycji oraz konfiguracji przestrzennej. Następnie omawiane są wskaźniki umożliwiające określanie charakterystyk struktur przestrzennych, czyli metryki krajobrazowe oraz sygnatury przestrzenne. Opisana jest także idea reprezentacji rastrów w postaci macierzy i wektorów współwystępowania. W następnej kolejności przedstawione są dwie metody analiz zmian pokrycia terenu. Pierwsza opiera się na analizie różnic na poziomie indywidualnych komórek w siatce rastra, a druga opiera się na analizie struktur przestrzennych występujących wewnątrz rastra. Wyjaśnione są także zagadnienia miar odległości i niepodobieństwa oraz ich wykorzystania w analizach przestrzennych. Przedstawiany jest także proces obliczenia niepodobieństwa między parami rastrów. W końcowej części rozdziału opisany jest sposób symulacji danych rastrowych o określonej kompozycji i konfiguracji przestrzennej, mający na celu przybliżenie czytelnikowi możliwości wygenerowania własnych danych rastrowych w sposób zbliżony do wykorzystanego w tym badaniu.

2.1 Struktury przestrzenne

McGarigal et al. (2009) określa, że znaczna część dziedziny ekologii krajobrazu opiera się na paradygmacie płatów. Według tej idei krajobrazy składają się z jednostek (płatów), które charakteryzuje się jako wyodrębnione obszary o jednakowej kategorii pokrycia terenu (Forman, 1995; Solon, 2002). Każdy krajobraz natomiast cechuje się pewną strukturą przestrzenną, której najbardziej podstawowymi charakterystykami są kompozycja i konfiguracja przestrzenna (Gustafson, 1998).

Kompozycja rastra opisuje zróżnicowanie i liczbę płatów poszczególnych kategorii pokrycia terenu bez uwzględniania informacji o ich lokalizacji w przestrzeni (Gustafson, 1998; Solon, 2002; Kozak et al., 2014). Konfiguracja (ułożenie) natomiast opisuje sąsiedowanie ze sobą poszczególnych płatów (Gustafson, 1998; Solon, 2002; Kozak et al., 2014). Kompozycja, konfiguracja, jak i inne różne cechy mogą następnie być opisywane na przykład za pomocą metryk krajobrazowych lub sygnatur przestrzennych.

2.2 Metryki krajobrazowe

Metryki krajobrazowe to algorytmy, które w sposób ilościowy charakteryzują właściwości przestrzenne płatów, grup płatów lub całych krajobrazów (McGarigal et al., 2023). Umożliwiają także analizę struktury przestrzennej krajobrazu na podstawie danych o pokryciu terenu (Pukowiec-Kurda et al., 2016).

Opracowano wiele różnych metryk, których celem jest opis różnych aspektów struktury przestrzennej rastrów (McGarigal et al., 2023). Można je podzielić na dwie podstawowe grupy: wskaźniki kompozycji (opisujące zróżnicowanie i liczbę płatów danego typu) oraz wskaźniki konfiguracji przestrzennej (opisujące sposób rozmieszczenia i sąsiedowania płatów) (Solon, 2002; Kozak et al., 2014).

Do przykładowych metryk krajobrazowych należą między innymi: procentowy udział poszczególnych typów pokrycia terenu (spatial share), liczba płatów (number of patches), średni rozmiar płatu (mean patch size), indeks średniego kształtu płatu (mean shape index – MSI), średnia odległość do najbliższego płatu tej samej kategorii (mean nearest neighbor), indeks różnorodności Shannona (Shannon Diversity Index – SHDI), indeks

średniego wymiaru fraktalnego (mean fractal dimension index) (Hesselbarth et al., 2019).

Szczególną zaletą metryk krajobrazowych jest to, że mogą one być obliczone dla różnorodnych jednostek przestrzennych, które mogą być zdefiniowane na podstawie wszelkich aspektów administracyjnych, geograficznych, biogeograficznych lub umownych (Pukowiec-Kurda et al., 2016). Jednostki te mogą obejmować zarówno granice gmin, zlewni, ekoregionów czy nawet abstrakcyjne obszary na mapie, co z kolei umożliwia wszechstronne stosowanie tych metryk w badaniach związanych z analizą krajobrazu.

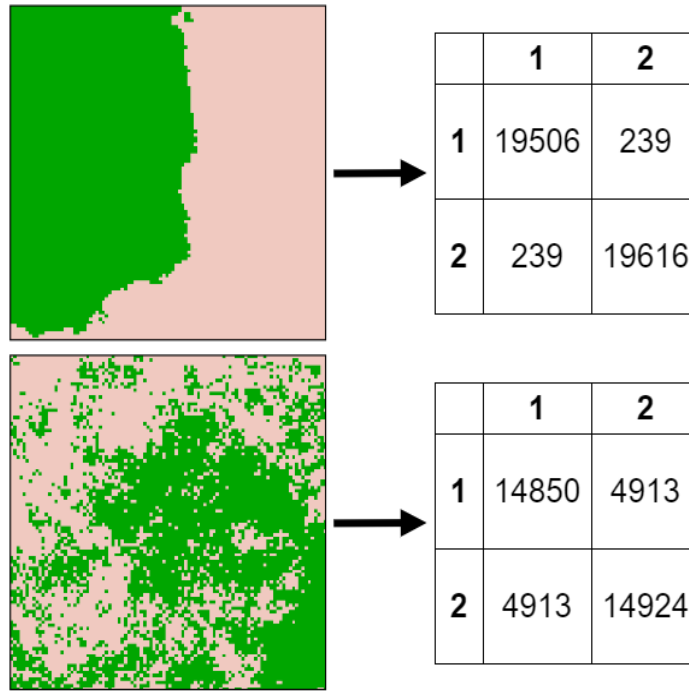
2.3 Sygnatury przestrzenne

Często w celu lepszej reprezentacji analizowanych rastrów możemy wykorzystywać także bardziej skomplikowane sygnatury przestrzenne. Sygnatura przestrzenna to statystyczny opis pewnych struktur przestrzennych występujących wewnątrz rastra (Jasiewicz et al., 2015; Nowosad, 2021). Są one dwuwymiarową reprezentacją kompozycji i konfiguracji przestrzennej rastra, czyli jego najbardziej podstawowych charakterystyk.

Przykładem sygnatury łączącej zarówno kompozycję, jak i konfigurację przestrzenną jest macierz współwystępowania. Jest to macierz o wymiarach k na k , gdzie k reprezentuje liczbę kategorii pokrycia terenu obecnych w analizowanym rastrze (Haralick et al., 1973; Jasiewicz et al., 2015). Macierz tą możemy skonstruować poprzez zliczanie kolejno wszystkich par sąsiadujących ze sobą komórek w rastrze. Wewnątrz tej macierzy, wartości ułożone na przekątnej odnoszą się do kompozycji rastra, natomiast pozostałe do jego konfiguracji. Przykład dwóch macierzy współwystępowania dla rastrów o zbliżonej kompozycji, ale różnej konfiguracji przestrzennej przedstawia Rycina 2.1.

Na podstawie macierzy współwystępowania mogą zostać obliczone różne miary wywodzące się z dziedziny teorii informacji (Nowosad et al., 2019). Przykładem takiej miary jest entropia brzegowa, która opisuje zróżnicowanie kompozycji rastra, czyli udziałów każdej z kategorii w rastrze. Entropia brzegowa może być obliczona zgodnie ze wzorem:

$$H(y) = - \sum_{j=1}^K p(y = c_j) \log_2 p(y = c_j)$$



Rycina 2.1: Przykład dwóch macierzy współwystępowania dla rastrów o zbliżonej kompozycji i różnej konfiguracji przestrzennej.

Kolejną miarą jest względna informacja wzajemna. Reprezentuje ona stopień sąsiadowania ze sobą kategorii w rastrze, czyli jego konfigurację przestrzenną. Względną informację wzajemną można obliczyć ze wzoru:

$$U = I(y, x) / H(y)$$

gdzie $I(y, x)$ oznacza informację wzajemną, liczoną ze wzoru:

$$I(y, x) = H(y) - H(y|x)$$

natomiast $H(y|x)$ reprezentuje entropię warunkową, obliczaną zgodnie ze wzorem:

$$H(y|x) = \sum_{i=1}^K \sum_{j=1}^K p(x = c_i, y = c_j) \log_2 p(y = c_j | x = c_i)$$

W celu porównywania ze sobą sygnatur dwóch rastrów w postaci dwuwymiarowej macierzy należy je sprowadzić do postaci jednowymiarowego wektora (histogramu), a następnie przeprowadzić jego normalizację, tak aby wszystkie wartości sumowały się do

1. Taka postać pozwala na obliczanie miar odległości lub podobieństwa, pozwalających na porównywanie histogramów wartości (Cha, 2007). Miary te następnie pozwalają określić stopień odmienności dwóch rastrów. Podejście to może być także wykorzystane w innych analizach przestrzennych, jak wyszukiwanie obszarów o podobnej strukturze przestrzennej, wykrywanie ich zmian oraz grupowanie obszarów o podobnej strukturze przestrzennej (Jasiewicz et al., 2015; Nowosad, 2021).

2.4 Metody analiz różnic pokrycia terenu

Zmiany pokrycia terenu w czasie lub różnice w pokryciu terenu pomiędzy obrazami można analizować przy użyciu wielu metod. Wiele z nich koncentruje się na analizie różnic na poziomie indywidualnych komórek w siatce rastra. Najbardziej podstawowym przykładem takiego podejścia jest analiza ilościowa różnic w pokryciu terenu. Zaletą tego podejścia jest przede wszystkim łatwość w wykonaniu analizy. Wystarczy zliczyć wszystkie komórki należące do poszczególnych kategorii dla wybranych rastrów, a następnie porównać ze sobą te wartości, aby otrzymać wynik informujący nas o ilościowych różnicach między analizowanymi rastrami. Analiza ilościowa najczęściej wykorzystywana jest w celu wskazania ogólnych trendów zmian pokrycia terenu dla określonego obszaru badań jak na przykład zmniejszanie się obszarów leśnych lub wzrost terenów zurbanizowanych.

Wszelkie metody analiz zmian pokrycia terenu opierające się na analizie poszczególnych komórek w siatce rastra są użyteczne na obszarach, gdzie zmiany między indywidualnymi komórkami dostarczają istotnych informacji. Ich przydatność jednak maleje, gdy informacja na poziomie pojedynczej komórki przestaje być tak istotna, na przykład dla rastrów o wysokiej rozdzielczości lub znacznym zasięgu przestrzennym (Jasiewicz et al., 2015). W takiej sytuacji bardziej efektywne staje się zastosowanie metod opartych na analizie struktur przestrzennych (ang. pattern-based change assessment) (Netzel et al., 2015).

Pozwalają one przede wszystkim na opis oraz obliczenie podobieństwa struktur przestrzennych. Głównym zamysłem tych metod jest przekształcenie danych z postaci

dużych rastrów zbudowanych z wielu indywidualnych komórek zawierających pojedyncze informacje w metryki krajobrazowe oraz sygnatury przestrzenne, a następnie porównanie ich za pomocą miar odległości lub niepodobieństwa. Zastosowanie metryk krajobrazowych w kontekście kompleksowych analiz przestrzennych ma jednak istotną wadę. Jako że pojedyncza metryka krajobrazowa reprezentuje wyłącznie jedną, konkretną charakterystykę analizowanego obszaru, to nie jest w stanie zdefiniować całej charakterystyki struktury przestrzennej danego rastra. W tym celu korzystniejsze może okazać się zastosowanie sygnatur przestrzennych. Dzięki temu, że są dwuwymiarową reprezentacją struktury przestrzennej rastrów, można je ze sobą porównywać przy użyciu szerokiej gamy istniejących miar odległości i niepodobieństwa. Umożliwia to także wykonywanie bardziej skomplikowanych analiz przestrzennych, jak wyszukiwanie, wykrywanie zmian, grupowanie i segmentacja (Nowosad, 2021).

2.5 Miary odległości i niepodobieństwa

Odległość oraz rozbieżność (inaczej niepodobieństwo) stanowią pewien policzalny stopień różnorodności pary obiektów. Największą różnicą między nimi jest to, że odległości są symetryczne, podczas gdy rozbieżności są niesymetryczne. Oznacza to, że wyłącznie dla miar odległości otrzymujemy identyczny wynik przy porównywaniu par obiektów A i B, jak i par B i A.

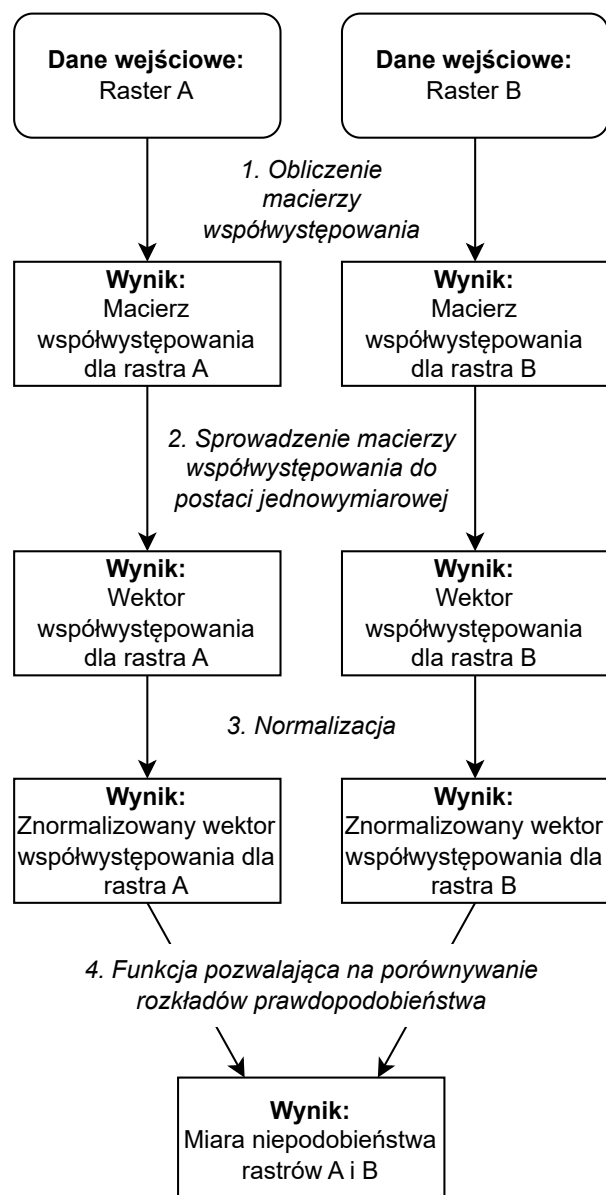
Niepodobieństwo jest przeciwieństwem podobieństwa. Ponadto, miary podobieństwa można łatwo przekształcić w miary niepodobieństwa (Niesterowicz et al., 2016). W związku z tym, w celu uproszczenia terminologii, wszystkie miary odległości, podobieństwa oraz te wywodzące się z dziedziny teorii informacji, które zostały wykorzystane w tej pracy, będą dalej zbiorowo nazywane miarami niepodobieństwa.

Na podstawie podobieństw syntaktycznych, wyróżnia się kilka grup rodzin miar niepodobieństwa (Cha, 2007): rodzina Minkowski (odległość euklidesowa, odległość Minkowskiego, odległość Manhattan), rodzina L1 (Canberra, Sorensen, Kulczynski), rodzina Intersection (Intersection, Wave Hedges, Ruzicka), rodzina Inner Product (Jaccard, Harmonic mean), rodzina Squared-chord (Fidelity, Matusita), rodzina Squared L2 (Clark, Pearson X2, Neyman X2), rodzina Shannon's Entropy (Jensen-Shannon, Kullback-Leibler),

a także miary będące połączeniem innych miar (Taneja, Kumar-Johnson) oraz miary wywodzące się z teorii informacji (informacja wzajemna, entropia Shannona). Wybór odpowiedniej miary niepodobieństwa zależy między innymi od rodzaju pomiaru lub sposobu reprezentacji obiektów (Cha, 2007).

2.6 Obliczenie niepodobieństwa rastrów

Pierwszym krokiem, jaki należy podjąć w celu obliczenia podobieństwa struktur przestrzennych danych rastrowych z wykorzystaniem metod opartych o sygnatury przestrzenne jest sprowadzenie rastrów wejściowych do postaci macierzy współwystępowania. Proces utworzenia macierzy współwystępowania polega na zliczeniu wartości każdej indywidualnej komórki rastra, a także przylegających do niej komórek (najczęściej czterech lub ośmiu). Przykładowe macierze współwystępowania widoczne są na Rycinie 2.1. Następnie, dwuwymiarową macierz należy sprowadzić do postaci jednowymiarowej, czyli wektora współwystępowania. Kolejnym etapem analizy jest normalizacja wektora współwystępowania. Po dodaniu do siebie wszystkich wartości tego wektora powinniśmy otrzymać wynik równy 1. Po wykonaniu powyższych czynności otrzymujemy reprezentację rastrów wejściowych, która umożliwia porównanie ich ze sobą przy użyciu miar niepodobieństwa między rozkładami prawdopodobieństwa, takich jak rozbieżność Jensena-Shannona. Proces obliczenia niepodobieństwa dwóch rastrów w postaci schematu przedstawia Rycina 2.2.



Rycina 2.2: Schemat procesu obliczenia niepodobieństwa dwóch rastrów.

Rozdział 3

Materiały

W tym rozdziale zostaną omówione najistotniejsze aspekty związane z formą przeprowadzonej ankiety. W pierwszej kolejności przedstawiony zostanie proces symulacji rastrów, który został wykorzystany do stworzenia zbioru danych o określonych parametrach kompozycji i konfiguracji przestrzennej. Następnie opisany zostanie sposób doboru odpowiednich pytań do ankiety. W końcowej części rozdziału omówione zostaną dane przestrzenne o pokryciu terenu CORINE Land Cover, które zostały wykorzystane do porównania zastosowania wybranych miar niepodobieństwa w kontekście analiz zmian pokrycia terenu.

3.1 Symulowanie rastrów o określonej kompozycji i konfiguracji przestrzennej

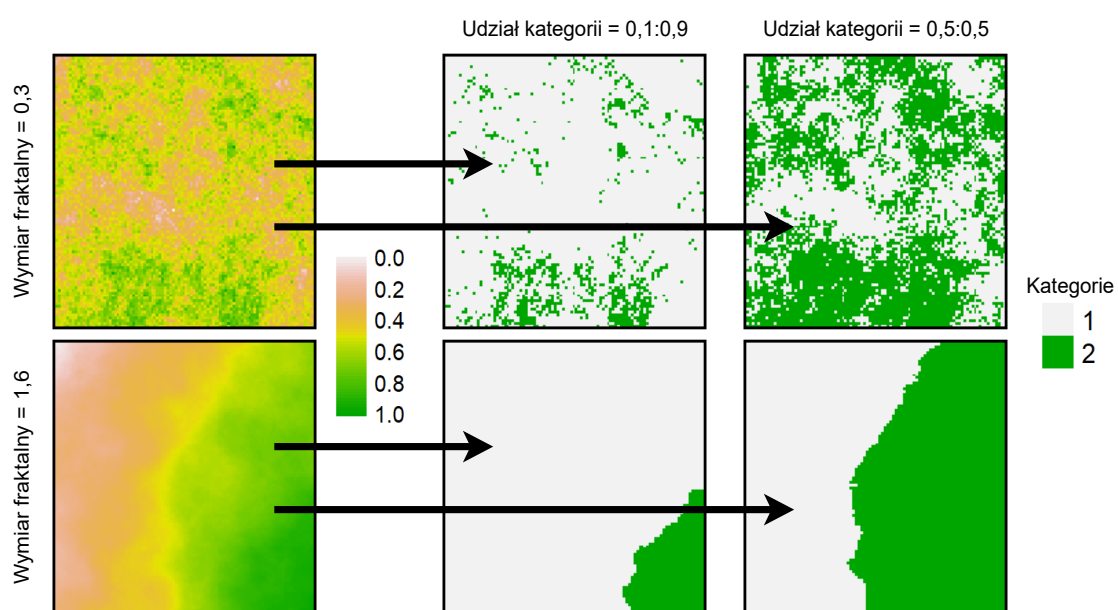
Najważniejszym założeniem przy tworzeniu zbioru rastrów do ankiety było przygotowanie ich w sposób umożliwiający uzyskanie pełnej reprezentacji wszystkich możliwych wartości kompozycji, jak i konfiguracji przestrzennej. Zbiór rastrów został przygotowany w języku programowania R (R Core Team, [2023](#)), w oparciu o wykorzystanie funkcji *nIm_fbm* z pakietu NLMR (Sciaini et al., [2018](#)). Powyższa funkcja umożliwia uzyskanie danych rastrowych wypełnionych wartościami zmiennoprzecinkowymi mieszczącymi się w zakresie od 0 do 1 oraz dowolnymi parametrami konfiguracji przestrzennej. Funkcja ta pozwala na symulację rastrów przy użyciu ułamkowych ruchów Browna, będących

uproszczeniem ruchów Browna (Schlather et al., 2015). W tej funkcji poziom autokorelacji między kolejnymi symulacjami jest kontrolowany za pomocą parametru wymiaru fraktalnego ("fract_dim"). W kontekście tego badania, parametr ten reguluje konfigurację przestrzenną. Oznacza to, że w przypadku, gdy "fract_dim" przyjmuje niską wartość, zbliżoną do 0, wartości w generowanym rastrze rozmieszczone są w sposób losowy, zbliżony do szumu. Natomiast w przypadku wysokiej wartości "fract_dim", zbliżonej do 2, na wynikowym rastrze tworzą się skupiska najwyższych i najniższych wartości, a przejścia pomiędzy nimi mają płynny, wygładzony charakter.

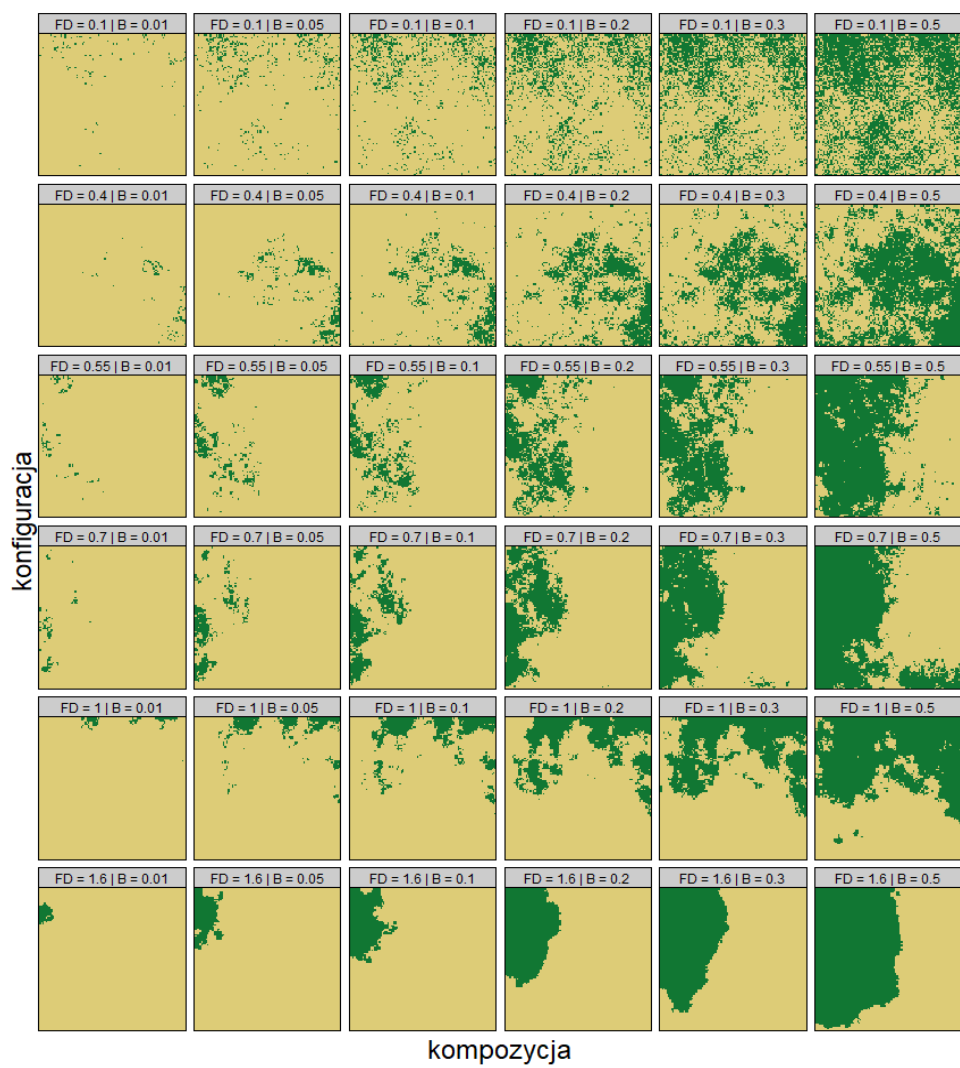
Następnie, aby otrzymać zbiór rastrów uwzględniający także pełen przekrój kompozycji należy przeprowadzić proces reklasyfikacji rastrów stworzonych w poprzednim kroku. Procedura ta polega na podziale każdego dotychczas utworzonego rastra na kategorie pokrycia terenu w różnych proporcjach, na przykład 90:10, 70:30 oraz 50:50 w przypadku rastrów zawierających wyłącznie dwie kategorie pokrycia terenu. Wykonanie tego procesu ułatwia między innymi funkcja *util_binarize* z pakietu *landscapetools* (Sciaini et al., 2018). W tej funkcji proporcje kategorii pokrycia terenu kontrolowane są za pomocą parametru "breaks". Przykładowo, ustawienie parametru "breaks" na poziomie 0.2 skutkuje otrzymaniem rastra o kategoriach pokrycia terenu w proporcjach 20 do 80. Oznacza to, że jedna z kategorii będzie pokrywała 20% komórek rastra, podczas gdy druga kategoria wypełni pozostałe 80% komórek. Na Rycinie 3.1 przedstawiony został przykład przygotowania rastrów podzielonych na dwie kategorie pokrycia terenu w sposób opisany powyżej.

Ostatecznie wygenerowane zostały zbiory rastrów składających się wyłącznie z dwóch lub trzech kategorii pokrycia terenu. Przykład jednego ze zbiorów rastrów przedstawia Rycina 3.2. Rastry zawierające trzy kategorie zostały uwzględnione w badaniu w celu próby wskazania czy liczba kategorii na rastrach ma wpływ na odpowiedzi udzielane przez ankietowanych.

Po utworzeniu zbioru danych rastrowych bardzo istotne było potwierdzenie, że obejmuje on pełen zakres rozkładu kompozycji i konfiguracji. Na potwierdzenie tego założenia pozwoliło obliczenie wybranych miar opisujących struktury przestrzenne: entropii oraz względnej informacji wzajemnej.



Rycina 3.1: Symulowanie rastrów o określonej kompozycji i konfiguracji przestrzennej



Rycina 3.2: Przykład zbioru wygenerowanych rastrów (2 kategorie pokrycia terenu)

3.2 Przygotowanie ankiety

Ostatnim krokiem przygotowania danych do ankiety było wybranie par rastrów tworzących poszczególne pytania tak aby uwzględniały one wszelkie możliwe różnice struktury przestrzennej rastrów. W tym celu, pytania w ankietach podzielone zostały na dwie grupy, wewnątrz których znalazły się po trzy podgrupy pytań.

W pierwszej kolejności respondenci zetknęli się z 24 pytaniami dotyczącymi rastrów uwzględniających wyłącznie dwie kategorie pokrycia terenu, a następnie z 24 pytaniami uwzględniającymi trzy kategorie pokrycia terenu. Pierwsza podgrupa pytań (6 par rastrów) składała się z par rastrów różniących się między sobą wyłącznie entropią. Podgrupa druga (6 par rastrów) zawierała wyłącznie rastry różniące się względną informacją wzajemną. Ostatnia podgrupa (12 par rastrów) składała się z pytań zróżnicowanych zarówno pod względem entropii, jak i względnej informacji wzajemnej.

Taki sposób doboru pytań pozwolił na zredukowanie liczby odpowiedzi wymaganych od respondentów, jak i ograniczenie wpływu błędu selekcji, który powstałby w wyniku niewłaściwego doboru pytań. Respondenci celowo nie zostali poinformowani o występujących różnicach pomiędzy kolejnymi pytaniami, ponieważ mogłoby mieć to wpływ na udzielane przez nich odpowiedzi, co z kolei mogłoby wpłynąć na ostateczne wyniki badania.

3.3 Dane CORINE Land Cover

Jednym z etapów porównania miar niepodobieństwa była eksploracja wyników tych miar przy zastosowaniu w analizie zmian pokrycia terenu na podstawie danych CORINE Land Cover (CLC). Dane CLC reprezentują szczegółowe informacje o pokryciu terenu, klasyfikując obszary geograficzne według różnych kategorii, takich jak lasy, tereny rolnicze, obszary zurbanizowane czy zbiorniki wodne. Stanowią one istotny instrument w analizie i monitorowaniu zmian środowiska, a także służą jako narzędzie wspierające procesy decyzyjne na poziomie europejskim.

Zbiory danych przestrzennych CORINE Land Cover stanowią integralną część programu CORINE (Coordination of Information on Environment), wprowadzonego przez Komisję

Wspólnot Europejskich w 1985 roku. Program ten został stworzony w celu skoordynowania przedsięwzięć związanych z gromadzeniem i przetwarzaniem informacji na temat stanu środowiska geograficznego w krajach należących do Wspólnoty Europejskiej oraz standaryzację tych danych w celu ułatwienia wymiany informacji między państwami członkowskimi (Bielecka et al., 2004).

Wyniki programu CORINE są udostępniane w formatach wektorowych ESRI i SQLite geodatabase oraz formacie rastrowym GeoTiff o rozdzielczości przestrzennej 100 metrów, co oznacza, że jedna komórka rastra obejmuje 1 hektar powierzchni. Do celów tej pracy, wykorzystane zostały dane CLC dla lat 1990 i 2018 udostępnione do pobrania w formacie GeoTiff na witrynie Copernicus Land Monitoring Service (<https://land.copernicus.eu/pan-european/corine-land-cover>). Dane te wykorzystują układ współrzędnych ETRS-LAEA (EPSG:3035).

Dane CLC są zorganizowane na trzech poziomach szczegółowości. Na najwyższym poziomie tej hierarchii wyodrębniono pięć głównych typów pokrycia terenu: tereny antropogeniczne, tereny rolne, lasy i ekosystemy seminaturalne, obszary podmokłe oraz obszary wodne. W celu uproszczenia analizy wyników, dane zostały poddane reklasyfikacji. W wyniku tego procesu zredukowano liczbę kategorii pokrycia terenu do wyłącznie dwóch: lasy i pozostałe obszary.

Rozdział 4

Wyniki

W tym rozdziale przeprowadzona zostanie analiza i podsumowanie wyników uzyskanych z ankiety. Wyniki zostaną zestawione z miarami niepodobieństwa uwzględnionymi w analizie.

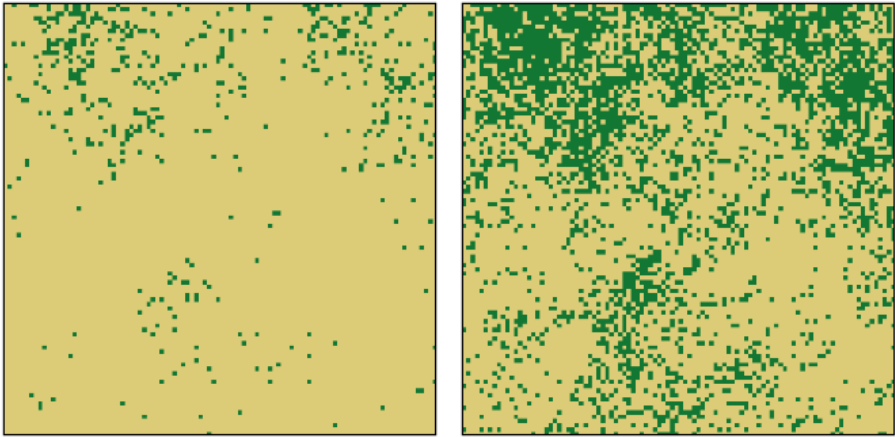
W celu zidentyfikowania potencjalnych związków pomiędzy percepcją zmian w pokryciu terenu przez ludzi a miarami niepodobieństwa, które te zmiany kwantyfikują przeprowadzona została ankieta. Głównym celem ankiety było aby uzyskanie wstępnych informacji na temat tego w jaki sposób różnice w entropii oraz względnej informacji wzajemnej między analizowanymi rastrami wpływają na subiektywne postrzeganie zmian w pokryciu terenu przez ludzi.

Badanie było realizowane w terminie od 21 do 24 listopada 2022 roku. Z uwagi na znaczną liczbę rastrów, które miałyby być przedstawione ankietowanym w trakcie badania, proces zbierania odpowiedzi respondentów przyjął formę ankiety online. Pozwoliło to respondentom na wygodny udział w badaniu przy użyciu komputera lub urządzenia mobilnego. Kwestionariusz stworzony został w formie aplikacji internetowej za pomocą języka programowania R, na podstawie pakietów **shiny** (2022) oraz **shinysurveys** (2021). Sama aplikacja umieszczona została na platformie *shinyapps.io* (<https://www.shinyapps.io/>). Przeprowadzenie ankiety w formie online umożliwiło systematyczne gromadzenie oraz przechowywanie odpowiedzi w formie tabelarycznej, ułatwiając tym samym dalszą analizę i interpretację danych. Respondenci stanowili

grupę 50 studentów drugiego roku studiów inżynierskich na kierunku Geoinformacja na Wydziale Nauk Geograficznych i Geologicznych Uniwersytetu im. Adama Mickiewicza. Wybór tej grupy respondentów oznacza, że byli oni już zaznajomieni z tematyką tworzenia i analiz map w formie rastrowej oraz pojęciem zmian pokrycia terenu.

Każdy z ankietowanych otrzymał do wypełnienia jeden z dwóch wcześniej przygotowanych zbiorów pytań. Każdy ze zbiorów składał się z 48 pytań, przy czym część pytań między zbiorami się pokrywała. Oznacza to, że łącznie uzyskano odpowiedzi na 93 unikatowe pytania. W każdym z pytań zadaniem respondentów było określenie podobieństwa na podstawie dwóch załączonych rastrów. W ramach badania respondenci mieli możliwość wyrażania swoich odpowiedzi za pomocą pięciostopniowej skali Likerta (Likert, 1932), która obejmowała poziomy od "Brak" przez "Bardzo małe", "Umiarkowane", "Bardzo duże" aż po "Pełne". Wykorzystanie skali Likerta o nieparzystej liczbie przedziałów, pozwoliło na zastosowanie przedziału środkowego, którego celem było reprezentowanie odpowiedzi neutralnych lub trudnych do określenia. Początkowo, zamiast skali Likerta planowano wykorzystać skalę liczbową, w zakresie mieszczącym się od 1 do 100, jednakże zrezygnowano z tego pomysłu, jako że znaczenie wartości na skali liczbowej może być interpretowane inaczej przez każdego respondenta oraz skala ta nie pozwala na uwzględnienie wspomnianej wcześniej odpowiedzi neutralnej. Przykład pytania przedstawionego respondentom ilustruje Rycina 4.1.

Łącznie uzyskane zostało 2400 odpowiedzi na pytania z ankiety. Podsumowanie uzyskanych odpowiedzi przedstawione zostało w Tabeli 4.1. Według ankietowanych prawie 36% par rastrów charakteryzowała się brakiem podobieństwa, 32,6% uzyskanych odpowiedzi wskazywało na bardzo małe podobieństwo, 18,1% na umiarkowane, 11,6% bardzo duże, natomiast mniej niż 2% wskazywało na pełne podobieństwo. Warto tutaj także zwrócić uwagę, że zestawienia wszystkich odpowiedzi w zależności od liczby kategorii widocznych na rastrach nie wskazują na znaczące różnice w liczbie odpowiedzi dla danej kategorii. Największą różnicę stanowi w tym przypadku kategoria "Bardzo duże", dla której liczba odpowiedzi dla rastrów z dwoma i trzema kategoriami pokrycia terenu różni się zaledwie o 2,7%. Najmniejszą różnicą charakteryzuje się kategoria "Pełne", gdzie liczba odpowiedzi pomiędzy zestawami różni się o jedyne 0,9%.



Pytanie 2/49: Określ podobieństwo (liczba kolorów i ich ułożenie) między dwoma obrazami

Brak Umiarkowane Pełne

Brak Bardzo małe Umiarkowane Bardzo duże Pełne

Rycina 4.1: Przykładowe pytanie z ankiety

Tabela 4.1: Podsumowanie odpowiedzi z ankiety

Typ odpowiedzi	Łącznie		Dwie kategorie		Trzy kategorie	
	Liczba odpowiedzi	[%]	Liczba odpowiedzi	[%]	Liczba odpowiedzi	[%]
Brak	862	35.9	420	35.0	442	36.8
Bardzo małe	783	32.6	398	33.2	385	32.1
Umiarkowane	434	18.1	211	17.6	223	18.6
Bardzo duże	278	11.6	155	12.9	123	10.2
Pełne	43	1.8	16	1.3	27	2.2
Suma	2400	100.0	1200	100.0	1200	100.0

Aby określić jakie odpowiedzi należały do grupy najczęstszych odpowiedzi dla poszczególnych pytań, obliczona została miara określana dalej Poziomem zgodności. Poziom zgodności każdego pytania został obliczony jako stosunek najczęściej udzielonej odpowiedzi względem całkowitej liczby odpowiedzi udzielonych na to pytanie. Poziomy zgodności ankietowanych w podziale na rodzaje pytań znajdują się w Tabeli 4.2. Całkowity poziom zgodności ankietowanych został oszacowany na 55%. Oznacza to, że 1321 z 2400 udzielonych odpowiedzi znalazło się w grupie najczęściej udzielonych odpowiedzi

Tabela 4.2: Poziom zgodności ankietowanych w podziale na rodzaje pytań

Rodzaj pytania	Liczba naj- częstszych odpowie- dzi	Liczba od- powiedzi	Poziom zgodności [%]
Różna entropia, różne RMI	429	704	61
Różna entropia, identyczne RMI	425	796	53
Identyczna entropia, identyczne RMI	467	900	52
Łącznie	1321	2400	55

na pytania. Pytania różniące się zarówno entropią, jak i względną informacją wzajemną cechowały się najwyższym poziomem zgodności odpowiedzi wynoszącym 61%, podczas gdy pytania różniące się wyłącznie entropią uzyskały wynik 53%, a pytania różniące się wyłącznie względną informacją wzajemną uzyskały wynik 52%.

Najwyższy poziom zgodności odpowiedzi osób ankietowanych wyniósł 92% i dotyczył pytania różniącego się zarówno entropią, jak i względną informacją wzajemną. Aż 24 z 26 osób wskazało na brak podobieństw między rastrami uwzględnionymi w tym pytaniu. Jest to interesujący wynik, ponieważ rastry w tym pytaniu wcale nie należały do par rastrów najbardziej zróżnicowanych pod względem entropii i względnej informacji wzajemnej. Pierwszy z rastrów charakteryzował się entropią na poziomie 0,08 oraz względną informacją wzajemną wynoszącą 0,09. W przypadku drugiego rastra, wspomniane wartości wynosiły odpowiednio 0,47 i 0,48. Oznacza to, że w przypadku obu miar różnica między parami entropii oraz wynikami względnej informacji wzajemnej wyniosły 0,39.

Najniższy poziom zgodności, czyli zaledwie 38%, osiągnęło aż 8 pytań. Wyłącznie dwa z nich dotyczyły pytań zawierających trzy kategorie pokrycia terenu, podczas gdy pozostałe - dwóch. 75% z tych pytań uwzględniało rastry różniące się pod względem względnej informacji wzajemnej (inna konfiguracja) przy zachowaniu tej samej entropii (identyczna kompozycja).

W kolejnym etapie analizy wyniki uzyskane z przeprowadzonej ankiety zostały zestawione z wynikami 45 różnych miar niepodobieństwa dla par rastrów uwzględnionych w ankiecie. Aby ocenić relacje między najczęstszymi odpowiedziami uczestników ankiety a

miarami niepodobieństwa, przeprowadzono analizę korelacji Spearmana. W ten sposób uzyskano ranking miar, który został przedstawiony w Tabeli 4.3.

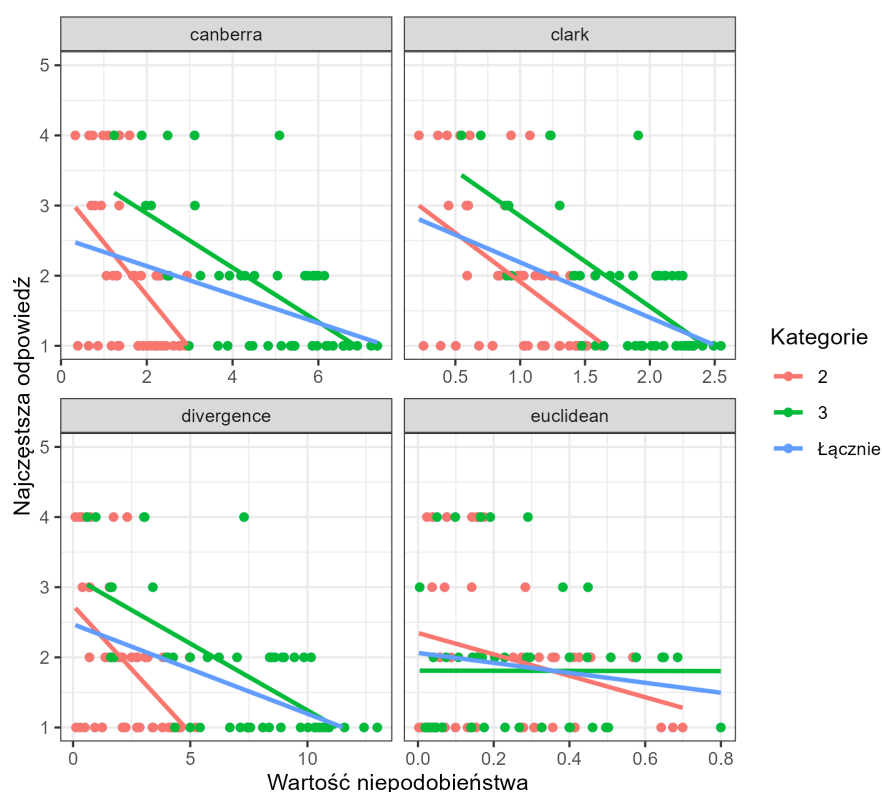
Spośród wszystkich analizowanych metod obliczania podobieństwa między parami rastrów, najlepszy wynik korelacji Spearmana z odpowiedziami ankietowanych osiągnęły *ex aequo* metody Divergence oraz Clark ze współczynnikiem korelacji równym -0,46. Do pozostałych miar, które osiągnęły dosyć wysokie wyniki korelacji i stanowią o znaczącym związku miar z odpowiedziami należą: Pearson (-0,44), Canberra (-0,38), Kumar-Johnson (-0,35), Wave Hedges (-0,33), Inner Product (-0,33), Additive Symmetric χ^2 (-0,30), Kullback-Leibler (-0,28), Taneja (-0,28) oraz Jeffreys (-0,25). Wyniki korelacji aż 21 miar mieszczą się w zakresie od -0,05 do 0,05, co wskazuje na ich bardzo niewielki lub brak związku z odpowiedziami udzielanymi przez respondentów. Do miar niepodobieństwa, które uzyskały najniższe współczynniki korelacji Spearmana należą odległość euklidesowa oraz kwadrat odległości euklidesowej, dla których wyniosły one 0,00. Wynik ten świadczy o kompletnym braku związku między wynikami tych miar a odpowiedziami ankietowanych.

Odpowiedzi ankietowanych z reguły charakteryzują się wyższym współczynnikiem korelacji z miarami niepodobieństwa obliczonymi dla pytań dotyczących rastrów uwzględniających wyłącznie dwie kategorie pokrycia terenu, niż uwzględniających trzy kategorie pokrycia terenu. Istotny wyjątek stanowią miary, które osiągnęły najlepsze wartości współczynnika korelacji Spearmana dla wszystkich odpowiedzi, takie jak metody Divergence oraz Clark, które także *ex aequo* osiągnęły najlepszy wynik korelacji z odpowiedziami na pytania z podziałem na trzy kategorie pokrycia terenu na poziomie -0,63. Najlepszy wynik korelacji Spearmana dla pytań uwzględniających rastry z dwoma kategoriami pokrycia terenu osiągnęła miara niepodobieństwa Canberra (-0,47), a następnie Wave Hedges (-0,46), Divergence (-0,45) i Clark (-0,45).

Do dalszej analizy wybrane zostały 4 miary niepodobieństwa: Divergence, Clark, Canberra oraz odległość euklidesowa. Trzy pierwsze zostały wybrane ze względu na to, że osiągnęły najlepsze wyniki w analizie korelacji Spearmana, natomiast odległość euklidesowa została wybrana w celu zestawienia z pozostałymi miarami.

Tabela 4.3: Zestawienie korelacji miar niepodobieństwa z odpowiedziami ankietowanych

Miara niepodobieństwa	Korelacja Spearmana		
	Łącznie	Dwie kategorie	Trzy kategorie
Divergence	-0.46	-0.45	-0.63
Clark	-0.46	-0.45	-0.63
Pearson	-0.44	-0.34	-0.48
Canberra	-0.38	-0.47	-0.57
Kumar-Johnson	-0.35	-0.34	-0.32
Wavehedges	-0.33	-0.46	-0.52
Inner product	-0.33	-0.23	-0.44
Additive symmetric chi2	-0.30	-0.32	-0.25
Kullback-Leibler	-0.28	-0.31	-0.20
Taneja	-0.28	-0.30	-0.23
Jeffreys	-0.25	-0.30	-0.18
Fidelity	0.21	0.30	0.11
Bhattacharyya	-0.21	-0.30	-0.11
Hellinger	-0.21	-0.30	-0.11
Matusita	-0.21	-0.30	-0.11
Średnia	-0.21	-0.30	-0.11
Jensen-Shannon	-0.19	-0.28	-0.10
Różnica Jensena	-0.19	-0.28	-0.10
Średnia harmoniczna	0.16	0.26	0.07
Squared chi^2	-0.16	-0.26	-0.07
Probabilistyczna symetryczna chi2	-0.16	-0.26	-0.07
Neyman	-0.14	-0.18	-0.05
Cosine	-0.05	0.16	-0.25
Manhattan	-0.04	-0.19	0.11
Sorensen	-0.04	-0.19	0.11
Soergel	-0.04	-0.19	0.11
Odległość Kulczyńskiego	-0.04	-0.19	0.11
Lorentzian	-0.04	-0.19	0.11
Intersection	0.04	0.19	-0.11
Non-Intersection	-0.04	-0.19	0.11
Czekanowski	-0.04	-0.19	0.11
Motyka	-0.04	-0.19	0.11
Podobieństwo Kulczyńskiego	0.04	0.19	-0.11
Tanimoto	-0.04	-0.19	0.11
Ruzicka	0.04	0.19	-0.11
Hassebrook	-0.04	0.14	-0.20
Jaccard	0.04	-0.14	0.20
Dice	0.04	-0.14	0.20
Gower	-0.02	-0.19	0.11
Średnia	-0.02	-0.17	0.14
Chebyshev	0.01	-0.14	0.16
Odl. euklidesowa	0.00	-0.15	0.15
Kwadrat odl. euklidesowej	0.00	-0.15	0.15
K divergence	NA	-0.20	NA
Topsoe	NA	-0.28	NA



Rycina 4.2: Regresja liniowa 4 wybranych miar niepodobieństwa z odpowiedziami ankietowanych

Analizując regresje liniowe miar Divergence, Clark oraz Canberra z najczęstszymi odpowiedziami udzielanymi przez ankietowanych (-Figure 4.2) można zauważyć wyraźną liniową relację o podobnym nasileniu zarówno dla pytań uwzględniających dwie jak i trzy kategorie pokrycia terenu. Tej liniowej relacji nie da się jednak zauważyć w przypadku odległości euklidesowej. W przypadku pytań z rastrami uwzględniającymi dwie kategorie pokrycia terenu miara ta osiągnęła wynik korelacji Spearmana równy -0,15, podczas gdy dla pytań z rastrami uwzględniającymi trzy kategorie pokrycia terenu wynik ten wyniósł 0,15. Oznacza to, że przy wzięciu pod uwagę wszystkich pytań, jej wyniki zestawione z najczęstszymi odpowiedziami ankietowanych mają charakter zbliżony do szumu.

Przy okazji omawiania wyników korelacji dla odległości euklidesowej warto wspomnieć, że zarówno odległość euklidesowa jak i kwadrat odległości euklidesowej osiągnęły dokładnie takie same wyniki korelacji Spearmana. Może to oznaczać, że podniesienie wyników odległości euklidesowej do kwadratu nie ma wpływu na ostateczny wynik analizy korelacji z wynikami ankiety.

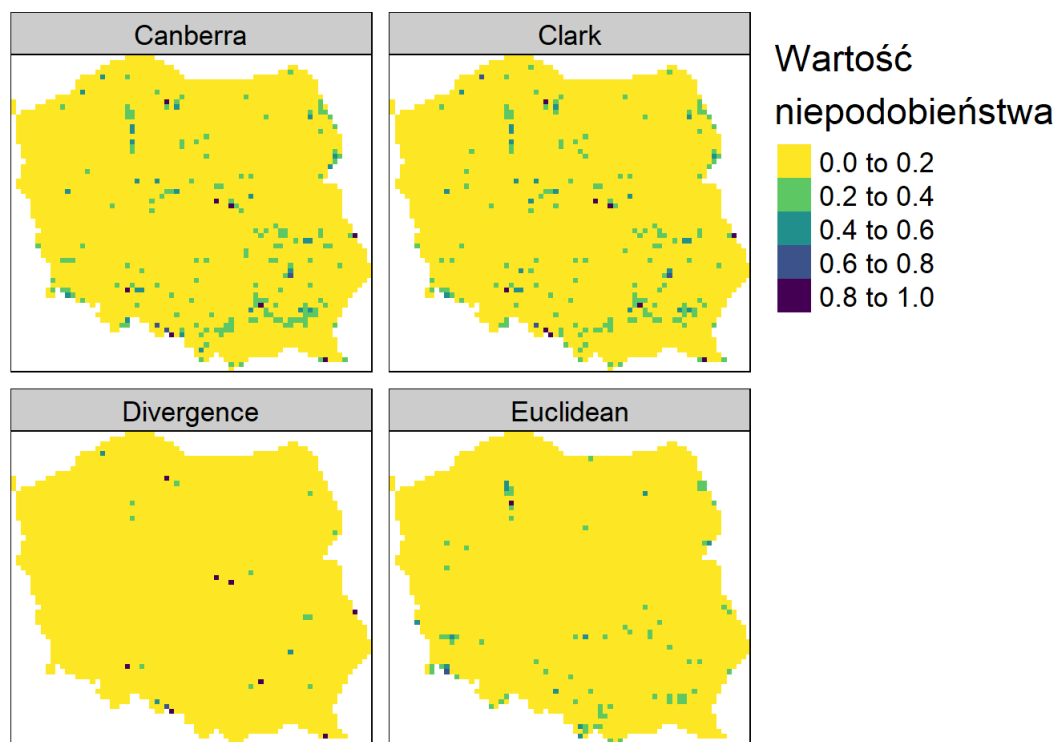
Tabela 4.4: Zestawienie korelacji między wybranymi miarami niepodobieństwa

	Canberra	Clark	Divergence	Euclidean
Canberra	1.00	0.99	0.83	0.54
Clark	0.99	1.00	0.84	0.48
Divergence	0.83	0.84	1.00	0.18
Euclidean	0.54	0.48	0.18	1.00

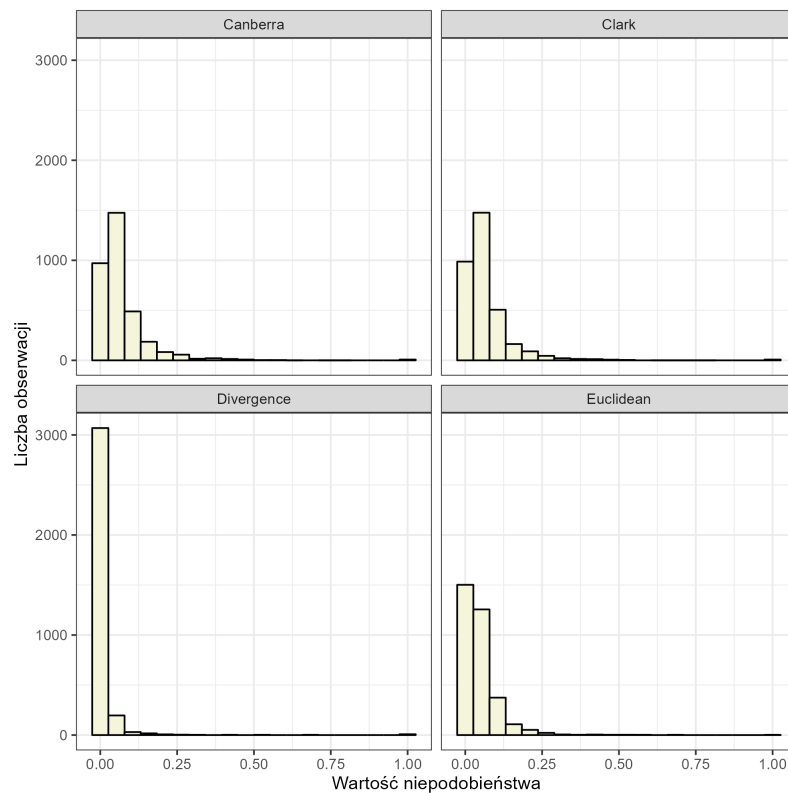
Dalsza część porównania wybranych miar niepodobieństwa oparta będzie na analizie wyników tych miar przy zastosowaniu w analizie zmian pokrycia terenu na podstawie danych rzeczywistych. W tym celu zostały wykorzystane dane CORINE Land Cover dla obszaru Polski dla lat 1990 i 2018, które zostały opisane w podrozdziale -Section 3.3. Dla uproszczenia analizy dane CLC zostały zreklasyfikowane tak aby uwzględniały wyłącznie dwie kategorie pokrycia terenu: lasy i pozostałe obszary.

Do oceny zmian pokrycia terenu zastosowano metody oparte na analizie struktur przestrzennych, opisane dokładniej w podrozdziale -Section 2.4. Dane wejściowe zostały podzielone na regularną siatkę kwadratów o wymiarach 100 na 100 pikseli (10 na 10 km). Następnie, dla tych obszarów obliczone zostały zmiany ich struktur przestrzennych dla danych z 1990 i 2018 roku wykorzystując do tego cztery wybrane wcześniej miary niepodobieństwa: Divergence, Clark, Canberra oraz odległość euklidesowa.

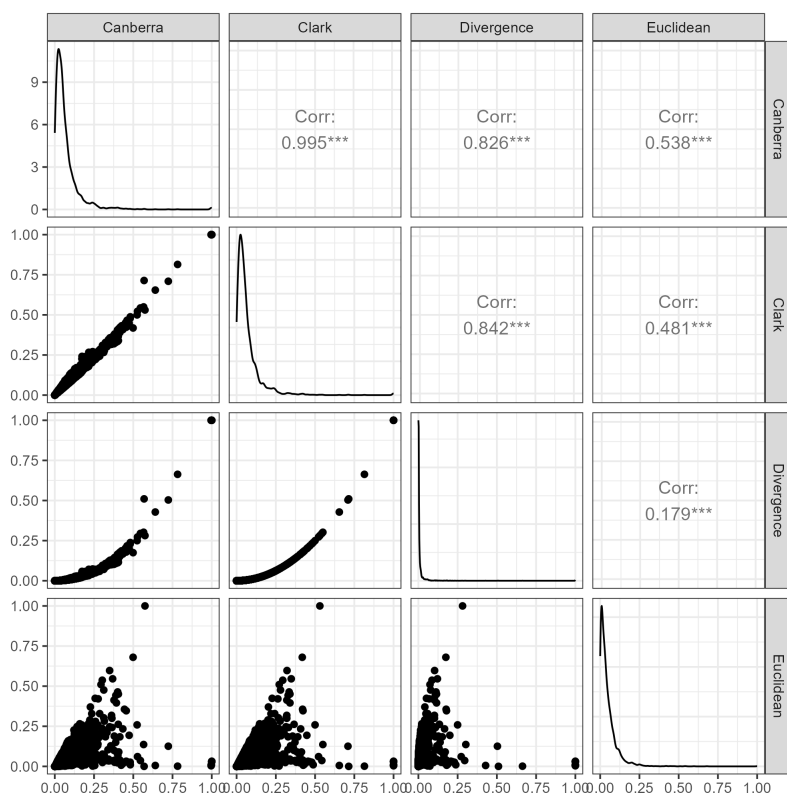
Ze względu na to że oryginalnie wyniki tych miar mieszczą się w różnych przedziałach wartości, zostały one przeskalowane do zakresu od 0 do 1. Dzięki temu można łatwiej ze sobą porównać wyniki tych miar. Należy jednak wziąć pod uwagę, że w takiej sytuacji wartość miar równa 0 niekoniecznie będzie oznaczać całkowity brak zmian w strukturze przestrzennej, a po prostu najmniejszą zmianę z całego zbioru danych. Wartość 1 natomiast reprezentować będzie obszary o największej zmianie struktury przestrzennej.



Rycina 4.3: Zestawienie map niepodobieństwa obszarów leśnych dla obszaru Polski dla lat 1990-2018



Rycina 4.4: Histogramy 4 wybranych miar niepodobieństwa



Rycina 4.5: Regresja liniowa 4 wybranych miar niepodobieństwa z odpowiedziami ankietowanych

Rozdział 5

Podsumowanie

Bibliografia

- Bielecka, E and A Ciołkosz (2004). Mapa pokrycia terenu w Polsce w skali 1:1 000 000 jako wynik wizualizacji bazy danych CLC-2000. *Polski Przegląd Kartograficzny* **T. 36, nr 4**, 274–287.
- Cha, SH (2007). Comprehensive Survey on Distance/Similarity Measures Between Probability Density Functions. *Int. J. Math. Model. Meth. Appl. Sci.* **1**.
- Chang, W, J Cheng, J Allaire, C Sievert, B Schloerke, Y Xie, J Allen, J McPherson, A Dipert, and B Borges (2022). *shiny: Web Application Framework for R*. R package version 1.7.4. <https://CRAN.R-project.org/package=shiny>.
- Comber, A, P Fisher, and R Wadsworth (2005). What is Land Cover? *Environment and Planning B: Planning and Design* **32**, 199–209.
- Forman, R (1995). *Land Mosaics: The Ecology of Landscapes and Regions*. Cambridge University Press. https://books.google.pl/books?id=sSRNU_5P5nwC.
- Głazewski, A (2006). Modele rzeczywistości geograficznej a modele danych przestrzennych. *Polski Przegląd Kartograficzny* **38(3)**, 217–225.
- Gustafson, EJ (1998). Quantifying landscape spatial pattern: what is the state of the art? *Ecosystems* **1(2)**, 143–156.
- Haralick, RM, K Shanmugam, and I Dinstein (1973). Textural Features for Image Classification. *IEEE Transactions on Systems, Man, and Cybernetics* **SMC-3(6)**, 610–621.
- Hesselbarth, MHK, M Sciaini, KA With, K Wiegand, and J Nowosad (2019). landscapemetrics: an open-source R tool to calculate landscape metrics. *Ecography* **42(10)**, 1648–1657. eprint: <https://nsojournals.onlinelibrary.wiley.com/doi/pdf/10.1111/ecog.04617>.

- Jasiewicz, J, P Netzel, and TF Stepinski (2015). GeoPAT: A toolbox for pattern-based information retrieval from large geospatial databases. *Comput. Geosci.* **80**, 62–73.
- Kozak, J, M Luc, K Ostapowicz, and E Ziolkowska (2014). “Pozyskiwanie i analiza danych o pokryciu terenu a badania struktury przestrzennej krajobrazu”. In: pp. 63–84.
- Likert, R (1932). A technique for the measurement of attitudes. *Archives of psychology*.
- Lu, D, P Mausel, E Brondízio, and E Moran (2004). Change Detection Techniques. *International Journal of Remote Sensing* **25**.
- McGarigal, K, S Cushman, M Neel, and E Ene (2023). McGarigal K, Cushman SA, Neel MC, Ene E. FRAGSTATS: Spatial Pattern Analysis Program for Categorical Maps. www.umass.edu/landeco/research/fragstats/fragstats.html.
- McGarigal, K, S Tagil, and S Cushman (2009). Surface metrics: an alternative to patch metrics for the quantification of landscape structure. *Landscape Ecology* **24**, 433–450.
- Netzel, P and TF Stepinski (2015). Pattern-Based Assessment of Land Cover Change on Continental Scale With Application to NLCD 2001–2006. *IEEE Transactions on Geoscience and Remote Sensing* **53**(4), 1773–1781.
- Niesterowicz, J and T Stepinski (2016). On using landscape metrics for landscape similarity search. *Ecological Indicators* **64**, 20–30.
- Nowosad, J (2021). Motif: an open-source R tool for pattern-based spatial analysis. *Landscape Ecology* **36**, 29–43.
- Nowosad, J and T Stepinski (2019). Information theory as a consistent framework for quantification and classification of landscape patterns. *Landscape Ecology* **34**.
- Pukowiec-Kurda, K and M Sobala (2016). Nowa metoda oceny stopnia antropogenicznego przekształcenia krajobrazu na podstawie metryk krajobrazowych. *Prace Komisji Krajobrazu Kulturowego* **nr 31**, 71–84.
- R Core Team (2023). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. Vienna, Austria. <https://www.R-project.org/>.
- Schlather, M, A Malinowski, P Menck, M Oesting, and K Strokorb (2015). Analysis, Simulation and Prediction of Multivariate Random Fields with Package Random Fields. *Journal of statistical software* **63**, 1–25.

- Sciaini, M, M Fritsch, C Scherer, and CE Simpkins (2018). NLMR and landscapetools: An integrated environment for simulating and modifying neutral landscape models in R. *Methods in Ecology and Evolution* **00**, 1–9.
- Solon, J (2002). *Ocena różnorodności krajobrazu na podstawie analizy struktury przestrzennej roślinności*. Prace Geograficzne - Polska Akademia Nauk. PAN IG i PZ. <https://books.google.pl/books?id=00dcAwAAQBAJ>.
- Trattner, J and L D'Agostino McGowan (2021). *shinysurveys: Create and Deploy Surveys in 'Shiny'*. R package version 0.2.0. <https://CRAN.R-project.org/package=shinysurveys>.